

Линейные вмешательства в представления больших языковых моделей для снижения отказов по этическим причинам

Федоров Артем
Ева Шелманова
Сергей Войтов
Алексей

AI Masters, NLA

29 Мая, 2025


Новый этап элайнмента: отказ на основе этических оценок в LLM

Современные LLM проходят новый этап элайнмента: их специально учат **отказываться** от ответов по этическим и другим чувствительным причинам. Такое поведение относительно этических ограничений закрепляется на уровне внутренних/латентных представлений модели; сейчас это широко встречается даже в open-source семействах или моделях, полученных через дистилляцию и переиспользование обучающих процессов от флагманских коммерческих моделей.

Вокруг такого «обученного отказа» возникает естественный конфликт интересов:

- **Разработчики моделей** стремятся сделать ограничения максимально устойчивыми и трудносняемыми: чтобы модель сохраняла безопасное поведение даже под давлением атакующих промптов и ухищрений.
- **Пользователи и исследователи** в ряде сценариев, напротив, пытаются заставить модель отвечать там, где она должна отказываться, и понять, насколько реалистично обойти такой элайнмент.

Таксономия методов снятия семантических блокировок



Наш фокус

Мы работаем на уровне представлений (representation-level): настраиваем простую линейную атаку по нескольким десяткам примеров, не требующую дообучения градиентными методами, и применяем ее на инференсе без требований на дополнительные вычислительные ресурсы (почти всегда за $O(1)$).

Основная гипотеза: низкоразмерное пространство отказа

Пусть $h_\ell(x) \in \mathbb{R}^d$ — скрытое представление на слое ℓ для запроса x . Мы рассматриваем линейное вмешательство

$$\tilde{h}_\ell(x) = h_\ell(x) + \alpha V, \quad V \in \mathbb{R}^{d \times k}, \quad k \ll d,$$

где V — низкоразмерное направление / подпространство, оценённое по нескольким десяткам примеров, а α — масштаб вмешательства.

Гипотеза

существует такое (ℓ, V, α) , что существенно уменьшается доля отказов на benign-запросах (*over-refusal* падает) и при этом сохраняется полезность и качество ответов на нормальных задачах




Figure: Визуализация сдвига в пространстве представлений

Как мы измеряем эффект: ASR, UPR и Perplexity

Attack Success Rate (ASR):

доля запросов из R , где после вмешательства модель вместо отказа даёт содержательный ответ:

$$\text{ASR} = \frac{1}{|R|} \sum_{x \in R} \mathbb{I}\{\text{“ответ” после атаки}\}.$$


Utility Preservation Rate (UPR):

доля запросов из B , где модель как отвечала до атаки, так и продолжает отвечать после неё:


$$\text{UPR} = \frac{1}{|B|} \sum_{x \in B} \mathbb{I}\{\text{“ответ до” и “ответ после”}\}$$

Perplexity (PPL) по Qwen-3VL-8B: индикатор того, что языковое качество и структура текста не деградируют.

Два подхода: как они видят структуру отказа



Refusal reduction: простая геометрия,
один из первых подходов



SOM: сложная геометрия на основе
класстеризации

Два подхода: как они вмешиваются и чего ожидать на практике

Метод Refusal reduction: простое линейное управление

- Находится фиксированное число “refusal-направлений” (по разности средних, линейному классификатору и т.п.).
- Вмешательство: добавляем к hidden-state $h_\ell(x)$ вектор αv , подбирая слой ℓ и силу α .
- Сильная сторона — **простота и скорость**, слабая — ограниченная устойчивость.

Метод SOM: проекция на кластерную структуру


- Строится **набор** направлений проекции на кластер безопасных эмбедингов.
- Возможна адаптация к домену, типу триггера или классу запросов.
- Это шаг от более статистических и грубых методов в сторону аккуратной настройки работы метода, подгонки под определенные сценарии.

Глобальная картина: Attack vs Utility для всех моделей

Каждая точка


— конкретная конфигурация (модель, метод, сила вмешательства). По оси X — **Utility Preservation**, по оси Y — **Attack Success**.

- правый верхний угол — желаемая зона: модель перестаёт «over-refuse», но остаётся полезной;
- видно, что разные модели и методы занимают разные области этого пространства.



Qwen + SOM: локальный трейд-офф атаки и полезности


Qwen Models: Сравнение метрик по вариантам SOM MD Ablation



Для семейства Qwen смотрим, как разные конфигурации SOM влияют на ASR и UPR.

- слабое вмешательство даёт умеренный рост ASR при почти неизменной полезности;
- агрессивные настройки SOM резко повышают ASR, но начинают «съедать» UPR и ухудшать баланс.



Траектории по силе вмешательства: Qwen vs Llama



- Qwen и Llama реагируют на один и тот же тип steering по-разному;
- для одних моделей есть «широкое плато» с хорошим балансом, для других — быстрый выход в зону деградации полезности.


SOM против Refusal Reduction: два взгляда на disalignment

Сравнение методов в пространстве Attack-Utility




Слева — все конфигурации **SOM**, справа — все конфигурации **Refusal Reduction (PCA)**

Сравнение моделей




Анализ перплексии атакованных моделей

Влияние Perplexity на метрики качества



Attack / Utility против Perplexity, оцененной внешней моделью Qwen-3VL-8B.


Тепловая карта перплексии по моделям и конфигурациям



Лучшие конфигурации: Pareto-баланс атаки и полезности

Для каждой модели выбираем конфигурацию, которая лежит в допустимой зоне по PPL и даёт хороший Pareto-баланс Attack/Utility.

- каждая «золотая» точка — рекомендуемая конфигурация линейного вмешательства для данной модели;
- видно, что правый верхний угол **не пуст**: существуют настройки, которые действительно снижают over-refusal и сохраняют полезность;
- одновременно видно, что для некоторых моделей эта зона узкая, а для других — существенно шире.



Результаты: что показали эксперименты

- **Линейное окно управления отказом:** для части моделей нашли низкоразмерные вмешательства, повышающие ASR при высоком UPR и приемлемой PPL.
- **Явный Pareto-трэйд-офф:** усиление вмешательства после порога даёт рост ASR ценой падения UPR и/или роста PPL.
- **Сильная модельная неоднородность:** у одних моделей широкое «рабочее окно», у более жёстко элайненных — узкая зона допустимых настроек.
- **SOM vs Refusal Reduction:** SOM агрессивнее (выше ASR, выше риск деградации), PCA-подход консервативнее, но стабильнее по UPR и PPL.
- **Перплексия как фильтр:** часть «успешных» атак с высокой PPL — фактически сломанные конфигурации, их нужно отсеивать.
- **Общий вывод:** линейный disalignment реалистичен, но работает как тонкая настройка, а не простой «выключатель» безопасности.

Итоги работы

- **Что сделали:** реализовали pipeline линейного disalignment'a (поиск направлений, вмешательство, оценка ASR/UPR/PPL).
- **Модели:** проверили несколько open-weight моделей семейств Qwen и Llama разных размеров.
- **Подтвердилось:** есть низкоразмерное «окно» управления отказом; SOM даёт более сильный эффект, PCA-подход стабильнее по UPR/PPL.
- **Ограничения:** нет универсального направления между моделями; рост ASR быстро покупается падением UPR и ростом PPL; эффект сильно зависит от конкретной модели.
- **Главный вывод:** линейный disalignment работает, но как аккуратная модель-специфичная настройка, а не универсальный «выключатель» отказа.

Проект и распределение работы

Репозиторий проекта:

<https://github.com/Dont4rootMe/llm-refusal-disalignment>

Команда и вклад:

- Федоров Артём — реализация алгоритма *SOM ablation*.
- Ева Шелманова — реализация алгоритма *refusal reduction*.
- Сергей Войтов — анализ существующих размеченных датасетов, постановка задачи *disalignment*, ручной отбор обучающей выборки, подготовка пайплайна данных.
- Алексей — пайплайн синтетических данных, отбор наиболее эффективных примеров, дополняющих реальные данные.