

Супербассейны: Кластеризуй, анализируй, ускоряй молекулярные **ГРАФ**оманы

Надежда Глушкова, Тимофей Розов, Зиганшин Илья

Большинство промышленных реакций происходят на поверхности катализаторов


Реакции происходят только наиболее энергетически выгодных участках, которые называют **активные центры** (на рис. это атомы рутения)

Самая **химическая реакция** представляет собой переход системы из одной энергетически выгодной конфигурации атомов в другую, разделенных энергетическим барьером, который системе надо преодолеть

Моделировать как проходят химические реакции
Нужно для:


- 1) посчитать выход реакции
(какая доля реагентов переходит в продукты)
- 2) скорость реакции
(сколько получается продукта в единицу времени)
- 3) понять механизм реакции
(через какие стадии проходят вещества)

Таким образом можно максимизировать эффективность химического процесса



**Разложение
аммиака
На катализаторе**

**Рекомбинация H
На SiO₂**



Кинетический Монте-Карло метод

- Можно явно считать уравнения движения или сделать приближения
- приближения КМС метода:
- Только переходы между центрами
- Никакой динамики внутри центров
- Центры собраны в решетку






Иллюстрация приближений метода




Реалистичная система
активных центров




Какие проблемы у КМС и зачем кластеризовать

- Если есть группа состояний системы разделенная низкими барьерами, то КМС траектория будет очень долго заперта в этой группе и метод сильно потеряет в скорости. Группы называют – **супербасейны**
- Если с помощью кластеризации найти супербасейны и заменить эту группу состояний одним суперсостоянием, то алгоритм не будет в них застревать
- Будем кластеризовать граф состояний системы



Шаги КМС с кластеризацией и без

На чем тестируемся



- У нас есть C++ кинетическая Монте-Карло модель на решетке, она выдает нам траекторию движения по графу состояний и превращает ее в матрицу интенсивностей перехода Q и матрицу вероятностей перехода P
- Проверяем для реакции рекомбинации атомов кислорода ($O+O \rightarrow O_2$) на поверхности SiO_2 в разряде постоянного тока(**на фото**), параметры подобраны под данные эксперимента, для численного эксперимента мы добавили «загрязнитель» блокирующий активные центры на поверхности (в реальности это мог бы быть **азот**), поток загрязнителя в 20 000 раз меньше потока кислорода
- Супербассейны будут отличаться по количеству заблокированных центров на решетке

Методы кластеризации

Второй сингулярный вектор работает как **детектор "узких мест"**.

Он ищет такой разрез системы, при котором вероятность перехода через границу будет минимальным и разделяет узлы графа по знакам компонент

АЛГОРИТМ

- Вычисляем **второй левый сингулярный вектор** (u_2).
- Сортируем элементы u_2 по возрастанию.
- Переставляем строки/столбцы матрицы P в этом порядке.
- Делим матрицу на 2 блока
- Повторить до победного

Время жизни системы в кластере

- Вектор средних времен удовлетворяет $-Q_{meta}t = 1$
- $Z = (-Q_{meta})^{-1}, t_i = \sum_{j \in A} Z_{ij}$
- $\langle t \rangle = \frac{1}{|A|} \sum_{i \in A} t_i$

Анализирует знаковую структуру собственных векторов, отвечающих собственным значениям, близким к 1 (пучок Перрона).

АЛГОРИТМ

- **Определение числа кластеров:** Находим группу собственных значений, близких к 1 и отделенных от остальной части спектра зазором.
- **Шаг 1.** Берём вектора из пучка, масштабируем их (отрицательные и положительные части отдельно), отбираем состояния s , где хотя бы одна компонента $|X_i(s)|$ превышает порог δ .
- **Шаг 2.** Зануляем все ненадёжные компоненты векторов по порогу θ . Группируем состояния по знаковым «отпечаткам» (+/-/0) и решаем задачу раскраски графа в «цвета отметок». Подбираем порог θ так, чтобы получить ровно k ядер будущих агрегатов. Если это сделать не получается, возвращаемся на предыдущий шаг и меняем δ .
- **Шаг 3.** Оставшиеся состояния, не имеющие четкой знаковой структуры, классифицируем на основании того, на какое из ядер больше всего оно похоже.

Отличия методов

- SVD кластеризация: **действует жадно**, не требует спектрального зазора, разбивает итеративно, не требует задания числа кластеров при старте
- Спектральная кластеризация: нужен спектральный зазор между пучком перрона и всеми остальными СВ, по СВ векторам перроновского пучка пытается разделить СРАЗУ на все кластеры, требует задать число кластеров изначально, требует многократного перебора гиперпараметров для поиска оптимального разбиения

Как будем измерять качество

- По **физическому времени жизни** системы в супербассейне: t
- По отношению **физического времени жизни** системы в супербассейне к среднему времени **самого быстрого процесса в системе** – на гистограммах «фактор ускорения» = $(1/r_{\min}) * t$
- По **среднему числу КМС** шагов внутри супербассейна
- Между методами кластеризации по **времени работы** и **числу найденных супербассейнов**

Результаты, система с 3000 состояний(размерность матрицы 12935)


Метрики метастабильных кластеров — PCCA+

12.3 сек, 90% состояний в кластерах, среднее ускорение на шаг ~100



Метрики метастабильных кластеров — SVD

0.7 сек, 55% состояний в кластерах, среднее ускорение на шаг ~100





Результаты, система с 9157 состояний(размерность матрицы 31041)

- Для большей системы, спектральная кластеризация не завелась.(34 мин.)

Метрики метастабильных кластеров — SVD

3.3 сек., 45 % состояний в кластерах, среднее ускорение на шаг ~400



Выводы

- Сравнили SVD и спектральную кластеризацию.
- SVD намного быстрее, но качество кластеров хуже
- Спектральная кластеризация дольше и не заработала на большой системе, но качество кластеров лучше и самих кластеров больше


Что вышло:

- Кластеризовать пространство состояний (2^{100} шт) и изучить его структуру (реально система бывает в 1000 – 10 000 состояний)
- Потенциально можно значительно ускорить КМС, на удачных шагах до 1000 раз(в среднем в 100), а по физическому времени до 10^8 - 10^9
- Т.е. КМС траектория попадет на кластер, то это будет невероятно эффективный шаг моделирования, но попадает она редко, в наших системах раз в 10 000 КМС итераций
- Появилась возможность восстанавливать статистику внутри редких бассейнов без явного семплирования очень длинной КМС траектории


Что НЕ вышло:

- Код КМС модели на с++, не сканирует граф состояний, а только строит вероятные траектории, 99% времени мы ходим по одним и тем же вершинам не заходя в новые состояния и не изучаем граф целенаправленно.

Мы изучили долгоживущие отклонения от равновесия(в них может зайти КМС)



Система в равновесии\Очень долгоживущем супербассейне



Мы **не** сумели изучить переходы между долгоживущими супербассейнами
Т.к. не изучаем граф целенаправленно, а КМС траектория туда никогда не пойдет

Что хотелось бы улучшить

1. Развить идею сканирования графа состояний для изучения переходов между долгоживущими супербассейнами
2. Портирование всего процесса кластеризации на c++ или сделать КМС в виде c++ ядра для питона
3. Прямое сравнение КМС внутри бассейна вместо поиска стационарного распределения. Есть ощущение, что такое метод более обоснован и будет давать более качественную статистику. Но это требует проверки
4. Завести спектральную кластеризацию на больших системах

Вклад(Надежда:Тимофей:Илья) = 1:1:1

Репозиторий: https://github.com/IliaFF/NLA_Graph_clusterization

Литература:

- [https://doi.org/10.1016/S0024-3795\(00\)00095-1](https://doi.org/10.1016/S0024-3795(00)00095-1) – статья о спектральной кластеризации
- [\(PDF\) An SVD approach to identifying metastable states of Markov chains\(PDF\) An SVD approach to identifying metastable states of Markov chains](#) – статья об SVD кластеризации
- <http://dx.doi.org/10.1063/1.4801869> - статья о методе супербассейнов
- <https://doi.org/10.3389/fchem.2019.00202> -Статья о KMC методе

Доп материалы

Интуиция

- Матрица переходов P должна соответствовать обратимой марковской цепи, $\pi_i * p_{ij} = \pi_j * p_{ji}$, где π – стационарное распределение.
- Для несвязанной цепи (P блочно-диагональна) собственное значение $\lambda=1$ имеет кратность k .
- Соответствующие собственные векторы X_i постоянны на каждом агрегате.
- Ключевое наблюдение: агрегаты можно идентифицировать по уникальной знаковой структуре ($\text{sign}(X_1(s)), \dots, \text{sign}(X_k(s))$) состояний s .

Вычислительная сложность (Асимптотика)

Обозначения:

- N — число состояний (размер матрицы).
- E — число ненулевых переходов (для разреженных матриц).
- K — число найденных блоков (количество запусков алгоритма).
- k — число итераций метода Арнольди/Ланцоша (обычно $k \ll N$).

Для разреженных матриц

1 - Поиск u_2 (SVD):

$$O(k \cdot E)$$

основная операция (умножение матрицы на вектор).

2 - Сортировка и Перестановка:

$$O(N \log N)$$

3 - Итоговая сложность:

$$O(K \cdot (E + N \log N)) \approx O(K \cdot E)$$

Вычислительная сложность (Асимптотика)

Обозначения:

- N — число состояний (размер матрицы).
- E — число ненулевых переходов (для разреженных матриц).
- K — число найденных блоков (количество запусков алгоритма).
- k — число итераций метода Арнольди/Ланцоша (обычно $k \ll N$).

Для плотных матриц

Лимитирующий шаг - поиск первых нескольких собственных с.з.:


$$O(k \cdot N^2)$$

Для разреженных матриц

Лимитирующий шаг - поиск первых нескольких с.з.:

$$O(k \cdot E)$$

Пример 5.1 из статьи: Восстановление структуры



- 1 – **Находим** второй левый сингулярный вектор u_2 .
- 2 – **Сортируем** его элементы по **возрастанию**.
- 3 – **Переставляем** строки и столбцы исходной матрицы в том же порядке
- 4 – **Разделяем** матрицу на части там, где u_2 меняет знак ($- \rightarrow +$)
- 5 – **Проверяем** : если плотность и размер блоков выше порога — повторяем для каждого блока (рекурсия).

Время жизни в кластере

- Для работы КМС метода требуется оценка времени жизни системы в кластере. матрица интенсивностей Q переходов в цепи, матрица вероятностей переходов P
- Вектор средних времен удовлетворяет $-Q_{meta}t = 1$
- $Z = (-Q_{meta})^{-1}, t_i = \sum_{j \in A} Z_{ij}$
- $\langle t \rangle = \frac{1}{|A|} \sum_{i \in A} t_i$
- Для обращения матрицы используем `pr.linalg.inv`, работает с плотными матрицами, но это не страшно, т.к. в кластерах всегда немного состояний. Работает через LU разложение $O(n^3)$. $SA = LU, A^{-1} = U^{-1}L^{-1}S$
Для оценки числа КМС шагов все тоже самое, но вместо Q используем P