


PowerSGD x Shadowheart SGD

EIGENVALION

Бегунов Григорий

Постановка задачи

- Рассмотрим задачу распределенного обучения



Постановка задачи

- Есть метод Shadowheart SGD, который гарантирует оптимальное время сходимости.
- Алгоритм лучше придумать нельзя, но что если взять мощный компрессор?

$$g^k = \sum_{i=1}^n w_i \sum_{j=1}^{m_i} c_{ij} \left(\sum_{l=1}^{b_i} \nabla f(x^k; \xi_{il}^k) \right) / \sum_{i=1}^n w_i m_i b_i.$$

$$w_i \stackrel{(a)}{=} \left(b_i \omega + \omega \frac{\sigma^2}{\varepsilon} + m_i \frac{\sigma^2}{\varepsilon} \right)^{-1}$$

$$\left(\sum_{i=1}^j \frac{1}{2\tau_{\pi_i} \omega + \frac{4\tau_{\pi_i} h_{\pi_i} \sigma^2 \omega}{\textcolor{red}{s} \times \varepsilon} + \frac{2h_{\pi_i} \sigma^2}{\varepsilon}} \right)^{-1} = \textcolor{red}{s} \quad (7)$$

$$\mathbb{E}[C_i(x)] = x, \quad \mathbb{E}[\|C_i(x) - x\|^2] \leq \omega \|x\|^2, \quad \forall x \in \mathbb{R}^d$$

Актуальность

Задача важна, поскольку сервера могут находиться на большом расстоянии друг от друга и на время затрачиваемое на gather или reduce операции необходимые для пересылки градиентов нельзя закрыть глаза (в отличие от broadcast'а точки от сервера воркерам).

Описание методов

$$\hat{g} = \sum_{i=1}^n \frac{\lambda_i t_i}{p_i} a_i$$

$$\mathbb{E}[(MU)U^\top] = M \mathbb{E}[UU^\top] = MI = M$$

Метод	Сложность	Координаты	Совместим?
RandK	$O(1)$	K	Да
Проекции (ранг k)	$O(k * m * n)$	$O(k * (m + n))$	Да
Atomo (бюджет s)	$O(m * n * \min(m, n))$	$O(s * (m + n))$	Нет
PowerSGD	$O(k * m * n)$	$O(k * (m + n))$	+ -
PowerSGD+			

PowerSGD

Идея: один шаг степенного метода + warm start

- Линейный, чтобы использовать reduce вместо gather
- Авторы говорят, что в современных больших моделях присутствует матрицы параметров имеют малый ранг, поэтому обновление весов с помощью матриц малого ранга является неявным регуляризатором.
- Собственные числа стохастических градиентов в современных моделях убывают, поэтому при малоранговой аппроксимации мало что теряется
- Быстрее Atomo, поскольку не нужно делать SVD

PowerSGD+ иногда считает честную малоранговую аппроксимацию, за счет чего достигается теоретическая сходимость





Минус: не на всех задачах работает без errorfeedback

Бенчмарк

- Linear matrix sensing
- Ищем матрицу X

$$\min_{X \in \mathbb{R}^{p \times q}} f(X) = \frac{1}{2m} \sum_{i=1}^m (\langle A_i, X \rangle - y_i)^2$$

Результаты



Выводы

- Целью было на практике улучшить Shadowheart SGD используя более продвинутый компрессор, чем RandK
- Не получилось это сделать с помощью PowerSGD компрессора, но удалось с помощью

ОСНОВНЫЕ ССЫЛКИ

- ATOMO: Communication-efficient Learning via Atomic Sparsification
- Shadowheart SGD: Distributed Asynchronous SGD with Optimal Time Complexity Under Arbitrary Computation and Communication Heterogeneity
- PowerSGD: Practical Low-Rank Gradient Compression for Distributed Optimization
- From PowerSGD to PowerSGD+: Low-Rank Gradient Compression for Distributed Optimization with Convergence Guarantees
- https://github.com/loIADK/nla_project