

All aboard the Tensor Train: denoising biomedical data and whatnot

big DATED tensor trains:

Даниил Хлебников

Алексей Раев


Тимофей Хирьянов

Елизавета Аристова

Денис Богачев

Ограничение "Проклятия Размерности" в биомедицинских данных

Данные в современной биологии часто характеризуются высокой внутренней размерностью



Гипотеза

Применение методов тензорной алгебры, в частности Tensor-Train SVD (TT-SVD), позволит обеспечивая эффективное хранение и обработку многомерных тензоров с сохранением точности аппроксимации

Цель

Сравнить эффективность и точность стандартного TT-SVD и стандартных методов при аппроксимации многомерных тензоров биомедицинских данных

Области применения

1. **Биоинформатика:** Реконструкция трехмерной структуры белка из ЕМ-фотографий (Cryo-EM). Снимки кластеризуются по ориентациям и позициям, образуя многомерный набор данных.
2. **Нейробиология:** Анализ пространственно-временных данных электроэнцефалографии (ЭЭГ).

Теоретическое введение

- **Проблема размерности:** тензор $A \in \mathbb{R}^{n_1 \times \dots \times n_d}$ содержит $n_1 \cdot \dots \cdot n_d$ элементов $\Rightarrow$ прямое хранение/операции дорогие при больших d .
- **Каноническое разложение** компактно, но:
 - вычисление ранга NP-трудно;
 - аппроксимация матрицы фиксированного ранга может быть поставлена некорректна ;
 - численные методы могут работать плохо.
- Разложение Такера устойчиво, но число параметров растёт экспоненциально по d .
- **TT/MPS:** линейная сеть тензоров (цепочка), позволяющая хранить многие тензоры за $O(dnr^2)$ при умеренных TT-рангах r .

ТТ-представление

Пусть $A \in \mathbb{R}^{n_1 \times \dots \times n_d}$.

ТТ-представление:

$$A(i_1, \dots, i_d) = \sum_{\alpha_1=1}^{r_1} \cdots \sum_{\alpha_{d-1}=1}^{r_{d-1}} G_1(i_1, \alpha_1) G_2(\alpha_1, i_2, \alpha_2) \cdots G_d(\alpha_{d-1}, i_d),$$

где $r_0 = r_d = 1$.

Размеры ядер (cores):

$$G_1 \in \mathbb{R}^{n_1 \times r_1}, \quad G_k \in \mathbb{R}^{r_{k-1} \times n_k \times r_k} \quad (2 \leq k \leq d-1), \quad G_d \in \mathbb{R}^{r_{d-1} \times n_d}.$$

При фиксированных i_k получаем произведение матриц $G_1(i_1) \cdots G_d(i_d) \in \mathbb{R}^{1 \times 1}$.

Развертка тензора

Для $k = 1, \dots, d - 1$ определим матрицу-развёртку:

$$A_k = A_k(i_1, \dots, i_k; i_{k+1}, \dots, i_d),$$

где $(i_1, \dots, i_k)$ нумеруют строки, а $(i_{k+1}, \dots, i_d)$ — столбцы.

Размер:

$$A_k \in \mathbb{R}^{(\prod_{s=1}^k n_s) \times (\prod_{s=k+1}^d n_s)}.$$

Связь с ТТ: ТТ-индекс α_k разделяет цепочку на левую и правую часть, то есть получается факторизация вида $A_k \approx (\text{левый блок}) \cdot (\text{правый блок})$ ранга $\leq r_k$.

Пример развертки

Пусть $A \in \mathbb{R}^{n_1 \times n_2 \times n_3}$. Тогда развёртка

$$A_2 = A_2(i_1, i_2; i_3) \in \mathbb{R}^{(n_1 n_2) \times n_3}$$

определяется как переупаковка индексов:

$$A_2((i_1, i_2), i_3) = A(i_1, i_2, i_3).$$

Конкретный пример. Возьмём $n_1 = n_2 = n_3 = 2$ и обозначим

$$a_{ijk} := A(i, j, k), \quad i, j, k \in \{1, 2\}.$$

Тогда матрица A_2 имеет размер 4×2 и строки соответствуют парам (i_1, i_2) в лексикографическом порядке:

$$(1, 1) \mapsto 1, \quad (1, 2) \mapsto 2, \quad (2, 1) \mapsto 3, \quad (2, 2) \mapsto 4.$$

Пример развертки

$$A_2 = \begin{pmatrix} A(1, 1, 1) & A(1, 1, 2) \\ A(1, 2, 1) & A(1, 2, 2) \\ A(2, 1, 1) & A(2, 1, 2) \\ A(2, 2, 1) & A(2, 2, 2) \end{pmatrix} = \begin{pmatrix} a_{111} & a_{112} \\ a_{121} & a_{122} \\ a_{211} & a_{212} \\ a_{221} & a_{222} \end{pmatrix}.$$

Основная теорема ТТ-разложения

Theorem (Теорема 2.1)

Если для всех $k = 1, \dots, d - 1$ развёртки A_k имеют ранги $\text{rank}(A_k) = r_k$, то существует ТТ-разложение тензора A с ТТ-рангами, не превосходящими r_k .

Эта теорема обосновывает построение ТТ через последовательные низкоранговые разложения.

TT-SVD

Цель: построить TT-приближение B тензора A с точностью ε .

Метод: последовательные усечённые SVD матриц-развёрток: на шаге k матрица размера $(r_{k-1}n_k) \times (n_{k+1} \cdots n_d)$ приближается рангом r_k ; матрица U даёт ядро G_k , а ΣV^T переносится на следующий шаг.

TT-SVD (алгоритм)

Algorithm 1: TT-SVD (по Algorithm 1)

Input: Тензор A , требуемая точность ε .

Output: Ядра $G_1, \dots, G_d$ ТТ-приближения B с $\|A - B\|_F \leq \varepsilon \|A\|_F$.

Вычислить порог $\delta = \frac{\varepsilon}{\sqrt{d-1}} \|A\|_F$.

$C \leftarrow A, r_0 \leftarrow 1$.

for $k = 1, \dots, d - 1$ **do**

// последовательные усечённые SVD

$C \leftarrow \text{reshape}(C, (r_{k-1} n_k) \times \frac{\text{numel}(C)}{r_{k-1} n_k})$.

 Усечённая SVD: $C \approx U \Sigma V^T, \|E\|_F \leq \delta$.

$r_k \leftarrow \text{rank}_\delta(C)$.

$G_k \leftarrow \text{reshape}(U, r_{k-1} \times n_k \times r_k)$.

$C \leftarrow \Sigma V^T$.

$G_d \leftarrow C$ (как матрица $r_{d-1} \times n_d$).

TT-Rounding

Мы сталкиваемся с проблемой : базовые операции в ТТ (сложение, произведения) увеличивают ТТ-ранги.

TT-rounding:

- 1 справа налево ортогонализация ядер (QR по строкам развёртки ядра);
- 2 слева направо усечённые SVD и перенос множителей в следующий core.

Результат: новые ранги равны δ -рангам развёрток и сохраняется точность $\|A - B\|_F \leq \varepsilon \|A\|_F$.

Итоговая сложность




Пусть $n_k \sim n$, $r_k \sim r$.

- Память TT: $\sum_{k=1}^d r_{k-1} n_k r_k \sim O(dnr^2)$.
- TT-SVD (Algorithm 1): последовательные SVD матриц масштаба $(nr) \times r \Rightarrow$ типично $O(dnr^3)$.
- TT-rounding (Algorithm 2): правый QR-проход $O(dnr^3)$ + левый SVD-проход $O(dnr^3) \Rightarrow O(dnr^3)$.
- Контракция с ранга-1: $O(dnr^2)$ (из статьи: последовательное умножение $\Gamma_1 \cdots \Gamma_d$).
- Скалярное произведение: порядка $O(dnr^3)$ при аккуратной организации (в противном случае $O(dnr^4)$).



cryoEM

Анализ структур требует восстановления плотностей молекул белков.

Криоэлектронная микроскопия предоставляет снимки в 2D проекциях





cryoSPARC



cryoEM

Для ab initio синтеза плотности нужны как можно более качественные 2D-классы. Можно делать:

- SVD-denoising исходных изображений
- TT-SVD / Tucker decomposition для стэков изображений из одного класса



cryoEM: что сделали

Пайплайн обработки от снимков до метрик полученной плотности. 99% Pythonic.

dkhlebn/
cryoEM_NLA_project

Pet project for cryoEM TT-SVD applications for NLA
course in AI Masters



1

Contributor

0


Issues

0

Stars

0

Forks



CTF estimation

Particle picking

2D Classification

Ab initio


Refinement

Metrics calculation


Optional врезка:
Micrographs SVD
denoising with
custom ranks

Optional врезка:
TT-SVD/Tucker 2D
classes denoising
with custom ranks


global and
local resolution;
b-factor;
angular distribution entropy;
particle retention;
2D class variance;
2D class retention.



cryoEM: пример workflow



Объект для бенчмарка: β -лактамаза (EMPIAR-10017)




cryoEM: форс-мажор

Здесь могла быть таблица метрик бенчмарка, но

Run	GFSC	LFSC	B-fct	P. retent.	2D Class retent.
0 x 0					
0 x TT					
0 x Tck					
SVD x 0					
SVD x TT					
SVD x Tck					

сервер, где
должны были
крутиться
бенчмарки,
вспотел 19.12



cryoEM: поверьте на слово



Что успели увидеть за время бенчмарков:

- от простого SVD **улучшается** распределение значений **CTF** (разрешение, обусловленное толщиной льда)
- **разрешение** после SVD всё же **ниже**
- Tucker, как и ожидалось, ест много памяти (1 раз упал)
- TT-SVD / Tucker продуцируют артефакты


Связано, наверное, с тем, что 2D-классификация делает сдвиги и повороты, которые не сохраняет. Получаем “отсутствие плотности”. Пробовали чинить – не вышло.



уплывает влево, но меньше выбросов



ДО



после

ЭЭГ


Сигналы разреженные

Много шума

Данные iEEG в типичном эксперименте формируют тензор:

- Электроды
- Время
- Частота
- Повторение

**Методы работы с ЭЭГ пытаются
одновременно выделить сигнал из шума и
интерпретировать его**




Вдохновение - статья

Tensor-powered insights into neural dynamics



- Традиционные методы машинного обучения (ML) и глубокого обучения для декодирования нейронных сигналов требуют векторизации данных
- Разрушаются пространственно-временные отношения

Гипотеза - использовать TT-SVD, Randomized TT-SVD и сравнить их с разложением Такера и CP



TT-SVD не дал улучшения в качестве, но значительно быстрее

Данные из [moabb](#) BNCI2014_001 Плейсхолдер картинки



Выводы

- Планировалось:
 - Сравнить методы декомпозиции данных iEEG и сравнить с результатами LS-STM
 - Понять применимость методов декомпозиции на cryoEM данных для восстановления плотности
- Получилось:
 - TT-SVD значительно отстает по качеству восстановления данных iEEG, значительно быстрее Tucker decomposition
 - TT-SVD/Tucker-based denoising хуже собственной модели denoising'a cryoSPARC

Планы:

- Хотелось бы всё-таки провести бенчмарк (т.к. набрали данные для 10 датасетов)



Вклады участников

1. Елизавета Аристова - модерация группы, работа с данными iEEG
2. Даниил Хлебников - применение TT-SVD в пайплайне CryoSPARC
3. Алексей Раев - разбор теории
4. Тимофей Хирьянов - TT-SVD для видео
5. Денис Богачев

ОСНОВНЫЕ ССЫЛКИ

Lorenz Richter, Leon Sallandt, Nikolas Nüsken, **Solving high-dimensional parabolic PDEs using the tensor train format**. Proceedings of the 38th International Conference on Machine Learning, 2021.

Gleb Ryzhakov, Ivan Oseledets, **Constructive TT-representation of the tensors given as index interaction functions with applications**. ICLR, 2023.

Berezutskaya, J., Vansteensel, M.J., Aarnoutse, E.J. et al. **Open multimodal iEEG-fMRI dataset from naturalistic stimulation with a short audiovisual film**. Sci Data, 2022.

Tangwiriyasakul, C., Premoli, I., Spyrou, L. et al. **Tensor decomposition of TMS-induced EEG oscillations reveals data-driven profiles of antiepileptic drug effects**. Sci Rep, 2019.

Zang, B., Sun, T., Lu, Y. et al. **Tensor-powered insights into neural dynamics**. Commun Biol, 2025.

CryoSPARC Team, Kelly Barber et al., **End-to-end automation of repeat-target cryo-EM structure determination in CryoSPARC**. bioRxiv preprint, 2025.

Приложение

TT-Rounding алгоритм

Algorithm 2: TT-rounding (по Algorithm 2)

Input: TT-тензор A с ядрами $G_1, \dots, G_d$, точность ε .

Output: TT-тензор B с уменьшенными рангами.

$$\delta \leftarrow \frac{\varepsilon}{\sqrt{d-1}} \|A\|_F.$$

(I) Ортогонализация справа налево

for $k = d, d-1, \dots, 2$ **do**

// QR по строкам

$M \leftarrow \text{reshape}(G_k, r_{k-1} \times (n_k r_k)).$

 Найти $M = R_k Q_k$, где строки Q_k ортонормированы.

$G_k \leftarrow \text{reshape}(Q_k, r_{k-1} \times n_k \times r_k).$

 Перенести R_k влево: умножить G_{k-1} по третьему индексу на R_k .

Algorithm 3: TT-rounding (по Algorithm 2)

(II) Сжатие слева направо

for $k = 1, 2, \dots, d-1$ **do**

// усечённые SVD

$M \leftarrow \text{reshape}(G_k, (r_{k-1} n_k) \times r_k).$

 Усечённая SVD: $M \approx U \Sigma V^T$, $\|E\|_F \leq \delta$.

$G_k \leftarrow \text{reshape}(U, r_{k-1} \times n_k \times r'_k).$

 Перенести $(V \Sigma)^T$ в G_{k+1} (умножение по первому индексу)